

5.  $m$  features + binary class

	$y_1$	$y_2$	...	$y_m$	$z$
$x_1$					0
$\vdots$					0
					0

i) boolean features:

$$p(0|x_{\text{new}}) = \frac{p(x_{\text{new}}|0)p(0)}{p(x_{\text{new}})} = \underbrace{p(y_1=?|0) \dots p(y_m=?|0)}_{p(x_{\text{new}})} \underbrace{p(0)}_{\text{prior} \rightarrow 1}$$

$p(z=0) = 1 - p(z=1)$

Todas as combinações possíveis:  $2^m - 1$ . Como todas as probabilidades somam 1, não preciso de calcular a última.

$p(1|x_{\text{new}}) \rightarrow 2^m - 1$ , não preciso do prior. TOTAL =  $2(2^m - 1) + 1$

ii) boolean features:

$$p(0|x_{\text{new}}) = \frac{p(x_{\text{new}}|0)p(0)}{p(x_{\text{new}})} = \underbrace{p(y_1=?|0) \dots p(y_m=?|0)}_{p(x_{\text{new}})} \underbrace{p(0)}_{\text{prior} \rightarrow 1}$$

$p(z=0) = 1 - p(z=1)$

Cálculo separado, mas segue  $p(y_1=0|0) = 1 - p(y_1=1|0)$ , logo só preciso de 1 por feature, logo  $\rightarrow m$ .

$p(1|x_{\text{new}}) \rightarrow m$ , não preciso do prior.

TOTAL =  $2m + 1$

Redução de exponencial ( $2^m$ ) para linear ( $m$ ).

iii) numeric features + binary class (exercício 4)

para cada classe

$z=0$   
 $\mu_0 = \begin{pmatrix} \end{pmatrix}_{1 \times m}$

$\Sigma_0 = \begin{pmatrix} \end{pmatrix}$  diagonal igual, logo  $\frac{m(m+1)}{2}$

$z=1$   
 $\mu_1 = \begin{pmatrix} \end{pmatrix}_{1 \times m}$

$\Sigma_1 = \begin{pmatrix} \end{pmatrix} \rightarrow \frac{m(m+1)}{2}$

Prior  $\rightarrow 1$

TOTAL =  $2\left(m + \frac{m(m+1)}{2}\right) + 1$

iv)

$$p(0|x_{\text{new}}) = \underbrace{p(y_1=?|0) \dots p(y_m=?|0)}_{p(x_{\text{new}})} \underbrace{p(0)}_{\text{prior} \rightarrow 1}$$

$p(z=0) = 1 - p(z=1)$

2 variáveis em cada  $y$  ( $\mu$  e  $\sigma$ ):  $2m$

$p(1|x_{\text{new}}) = 2m$ , não preciso do prior.

TOTAL =  $4m + 1$